

Package de Clustering de Variables sous R

Présenté par:

Olivier BOROT

Léo-Paul KNOEPFFLER

Perrine IBOUROI

Master 2 SISE

Architecture Logicielle : Le Choix de R6

Pourquoi R6 ?

▶ Sémantique de Référence :

Les méthodes R6 peuvent modifier l'état de l'objet en place, ce qui permet un style de programmation plus proche des langages POO classiques

▶ Encapsulation Stricte :

Distinction claire entre méthodes/attributs public et private.

▶ Héritage et Polymorphisme :

Factorisation du code commun et ajout facile de nouveaux algorithmes.

▶ Performance :

Bonne performance pour les algorithmes itératifs.

La Classe Abstraite BaseClusterer

Attributs Publics

<code>data</code> : DataFrame des données	<code>n_clusters</code> : Nombre de clusters
<code>clusters</code> : Assignations (NULL avant fit)	<code>fitted</code> : Booléen d'ajustement
<code>standardize</code> : Standardisation	<code>max_iter</code> : Itérations max

Méthodes Publiques

Méthode	Description
<code>fit()</code>	Ajuste le modèle aux données (abstraite)
<code>predict(new_data)</code>	Prédit les clusters pour nouvelles variables
<code>get_results()</code>	Retourne DataFrame avec assignations
<code>get_cluster_members(k)</code>	Retourne noms des variables du cluster k

Méthodes Privées

<code>validate_data()</code> : Vérification cohérence	<code>check_fitted()</code> : Vérification état	<code>standardize_data()</code> : Standardisation
---	---	---

Algorithme 1 : K-Means Clusterer

Principe et Caractéristiques

▶ Algorithme Itératif :

Réallocation dynamique des variables dans les clusters, basée sur la minimisation de l'inertie intra-cluster.

▶ Données Mixtes :

Support des données quantitatives et qualitatives via des métriques adaptées.

▶ Stratégies d'Initialisation :


Différentes approches: homogeneity++, correlation-based, random

▶ Exécutions Multiples :

Exécutions répétées avec différentes initialisations pour augmenter la robustesse.

▶ Convergence :

Critères de convergence basés sur la stabilité des assignations ou le nombre d'itérations.



Algorithme 2 : Divisive Clusterer

Principe Fondamental

- ▶ **Approche Descendante :**
Débute avec un seul cluster contenant toutes les variables.
- ▶ **Inspiration SAS :**
Basée sur le PROC VARCLUS du logiciel SAS.
- ▶ **Division Itérative :**
Divise récursivement chaque cluster en deux sous-clusters.

Méthode de Division

- ▶ **Sélection du Cluster à Diviser :**
Critère : Cluster avec la plus grande seconde valeur propres (λ_2).
Explication : une λ_2 élevée signale une hétérogénéité (présences de sous groupes)
- ▶ **Mécanisme de division:**
ACP sur le cluster : Extraction des 2 premières composantes
Rotation Varimax : Étape cruciale pour polariser les corrélations et clarifier l'appartenance
- ▶ **Assignation :**
Chaque variable rejoint le sous-groupe (composante rotée) avec lequel elle a la plus forte saturation au carré.

Critères d'Arrêt

- ▶ **Taille Minimale :**
Arrête si un cluster atteint la taille minimale spécifiée.
- ▶ **Critère d'arrêt :**
 - Ratio de Valeurs propres (λ_2/λ_1) : Arrêt si le ratio est faible
 - Critère de Kaiser : Arrête si la deuxième valeur propre est inférieure à 1.
- ▶ **Nombre de Clusters :**
Arrête si le nombre de clusters cible est atteint.

Algorithme 3 : Modalities Dice Clusterer

Objectif

Regrouper les **modalités des variables qualitatives** en clusters homogènes.

Caractéristiques

- ▶ **Approche** : Traitement direct du tableau disjonctif complet
- ▶ **Données Qualitatives** : Spécialisé pour les variables catégorielles (avec une discrétisation automatiques des variables quantitatives)
- ▶ **Mesures Adaptées** : Indices de similarité pour mesurer l'association entre les modalités

Avantages

- ▶ Interprétation factorielle
- ▶ Dendrogramme pour visualisation hiérarchique
- ▶ Méthodes de recoupage flexibles
- ▶ Statistiques et diagnostics détaillés

Méthode Hybride

1. Préparation de la matrice Disjonctive

Encodage des données catégorielles en binaire (One-Hot Encoding)

Analyse des motifs de co-occurrences entre modalités

2. Calcul des distances (Coeur de l'algo)

indice de Dice : Mesure la similarité basée sur la présence conjointe (ignore la co-absence)

V de Cramér : Alternative statistique basée sur le Chi-2

3. Classification Ascendante Hiérarchique (CAH)

Agrégation hiérarchique basée sur ces distances

Sélection du Nombre de Clusters

Méthode du Coude

Analyse de la variance intra-cluster pour identifier le point d'inflexion (coude) où l'ajout de clusters n'améliore plus significativement la variance expliquée.

- ▶ Simple à interpréter
- ▶ Basée sur la variance
- ▶ Méthode par défaut

Méthode de la Silhouette

Mesure de la cohérence des clusters en calculant la distance moyenne intra-cluster comparée à la distance inter-cluster pour chaque observation.

- ▶ Mesure de cohésion
- ▶ Valeurs entre -1 et 1
- ▶ Robuste et fiable

Indice Calinski-Harabasz

Ratio entre la variance inter-cluster et la variance intra-cluster.
Plus la valeur est élevée, meilleure est la séparation des clusters.


- ▶ Ratio inter/intra
- ▶ Valeurs positives
- ▶ Pseudo-F statistique

Visualisation des Résultats

Outils Graphiques


► Cercle des Corrélations

Positionnement des variables et des clusters dans un espace de faible dimension.




► Dendrogramme

Arbre hiérarchique pour DivisiveClusterer et MCA HClusterer.




► Heatmap des Corrélations

Visualisation des liens entre variables au sein et entre les clusters.



► Graphe de Réseau

Représentation des clusters comme des communautés avec connexions.



L'Application R Shiny

Objectif

Application R Shiny pour l'exploration et l'application du package M2RClust.

Architecture et Programmation Réactive

▶ Programmation Réactive :

Mise à jour dynamique des résultats en fonction des paramètres utilisateur.

▶ Fonctionnalités Transversales :

Intégration des modules de validation et visualisation.

▶ Interface Intuitive :

Contrôles simples pour la configuration du clustering.

Workflow Utilisateur

1. Chargement des Données : Importation et pré-traitement des données.

2. Configuration du Clustering : Choix de l'algorithme et des paramètres.

3. Analyse et Visualisation : Affichage des résultats et graphiques interactifs.

The screenshot displays the 'Clustering my data !' application interface. At the top right, it shows 'data: autos.xls', 'Change the Theme', and 'English' buttons. The main navigation bar includes 'Home', 'Upload Data', and 'Clustering'. Below this, there are tabs for 'Configuration', 'PDDP Results', 'MCA/Hclust Results', and 'K-Means Results'. The 'Configuration' tab is active, showing the 'Clustering Configuration' section. This section includes a 'Select Clustering Algorithm' dropdown menu set to 'K-Means' and a 'Number of Clusters' input field set to '3'. Below this is the 'K-Means Parameters' section, which contains several controls: a 'Standardize Data' checkbox that is checked, a 'Maximum Iterations' input field set to '100', a 'Tolerance' input field set to '0.0001', a 'Seed' input field set to '42', a 'Number of Initializations' input field set to '10', and an 'Initialization Method' dropdown menu set to 'Homogeneity++'.

Patrons de Conception

Template Method

Définit le squelette des algorithmes dans la classe BaseClusterer. Les sous-classes peuvent surcharger des hooks spécifiques pour ajouter des validations ou des traitements particuliers.

- ▶ Factorisation du code
- ▶ Structure commune
- ▶ Extensibilité contrôlée

Strategy

Permet la sélection dynamique des stratégies d'initialisation dans KMeansClusterer. Chaque stratégie est encapsulée dans une méthode privée et sélectionnée via un switch.

- ▶ Flexibilité algorithmique
- ▶ Sélection à l'exécution
- ▶ Évite les optima locaux

Lazy Loading

Diffère les calculs coûteux (ex: ACP globale) jusqu'à leur utilisation. Les résultats sont cachés et calculés à la demande pour optimiser les performances.

- ▶ Optimisation performance
- ▶ Économie de ressources
- ▶ Calcul à la demande

Tests et Qualité du Code

Couverture des Tests

test-00_utils.R

~200 lignes

test-01_base_clusterer.R

~290 lignes

test-02_kmeans_clusterer.R

~675 lignes

test-03_mca_hclust.R

~379 lignes

test-04_PDDP_clusterer.R

~889 lignes

Types de Tests

- ▶ **Instanciation** : Paramètres valides et invalides
- ▶ **Convergence** : Validation des algorithmes
- ▶ **Reproductibilité** : Cohérence avec seed
- ▶ **Cas Limites** : Gestion des erreurs
- ▶ **Intégration** : Compatibilité entre modules

Standards de Codage

- ▶ **Conventions de Nommage** : snake_case pour les fonctions et variables
- ▶ **Documentation** : Commentaires détaillés et roxygen2
- ▶ **Style** : Indentation 2 espaces, longueur max 80 caractères
- ▶ **Encapsulation** : Distinction public/private stricte
- ▶ **Validation** : Vérification systématique des entrées

Métriques de Qualité

Framework : testthat pour les tests unitaires

Validation : Vérification de l'état et des données

Messages : cat() pour progression, warning() pour avertissements

Robustesse : Gestion complète des erreurs et cas limites

Conclusion et Perspectives

Bilan du Projet

- ▶ **Package Complet :**
M2RClust est un package structuré pour le clustering de variables sous R.
- ▶ **Architecture R6 :**
Utilisation de la POO moderne pour garantir l'extensibilité.
- ▶ **Trois Algorithmes :**
K-Means, Divisive Clusterer, et Modalities Dice clusterer couvrent différents types de données.
- ▶ **Validation Rigoureuse :**
Validation des entrées et vérification de l'état pour prévenir les erreurs.
- ▶ **Tests Unitaires :**
Couverture étendue des tests pour assurer la fiabilité du code.
- ▶ **Interface Shiny :**
Application conviviale pour l'exploration interactive des données.

Perspectives Futures

- ▶ **Optimisation :**
Amélioration des performances pour les très grands jeux de données via parallélisation.
- ▶ **Nouveaux Algorithmes :**
Intégration de méthodes complémentaires (clustering spectral, basé sur la densité).
- ▶ **Fonctionnalités Shiny :**
Ajout d'exportation de rapports automatiques et de visualisations interactives avancées.
- ▶ **Publication :**
Soumission du package à CRAN pour une distribution officielle.